

# Deteksi Penyakit Daun *Camellia Sinesis* Menggunakan Metode Convolutional Neural Network (CNN) Dengan Arsitektur VGG16

Sindy Gayatri<sup>1\*</sup>, Melani<sup>2</sup>, Hesti Amalia Putri<sup>3</sup>, Annisa Nursetiani<sup>4</sup>

<sup>1,2,3,4</sup>Universitas Bina Sarana Informatika

J. Raya Cemerlang No.8, Sukakarya, Kec. Warudoyong, Kota Sukabumi, Jawa Barat 43135, Indonesia

e-mail: <sup>1</sup>sindygayatri55@gmail.com, <sup>2</sup>xxxx@xxxx.xxx, <sup>3</sup>e-mail: xxxx@xxxx.xxx

**Abstrak** - *Camellia sinensis* atau daun teh memiliki peran penting dalam perekonomian Indonesia, namun produksi daun teh sering terhambat oleh penyakit daun seperti *Brown Blight* yang disebabkan oleh *Colletotrichum camelliae*. Penelitian ini bertujuan mendeteksi penyakit pada daun *Camellia sinensis* menggunakan metode *Convolutional Neural Network* (CNN) dengan arsitektur VGG16. Dataset yang digunakan mencakup berbagai kategori penyakit, termasuk *Anthrachnose*, *Algal Leaf*, *Bird Eye Spot*, *Brown Blight*, *Gray Blight*, *Red Leaf Spot*, *White Spot*, serta kategori *Healthy*. Model dilatih selama 50 epoch dengan akurasi pelatihan akhir mencapai 97.03% dan loss sebesar 0.2122, sementara evaluasi pada dataset pengujian menunjukkan akurasi 68.59% dan loss 0.8518. Analisis prediksi individual terhadap sampel ke-26 menunjukkan keberhasilan model dalam memprediksi *Algal Leaf* dengan probabilitas 99.37%. Hasil penelitian ini mengindikasikan bahwa arsitektur VGG16 efektif untuk deteksi penyakit pada daun *Camellia sinensis*, dengan saran untuk meningkatkan generalisasi model melalui teknik augmentasi data, penambahan dataset, dan optimasi parameter pelatihan. Penelitian ini berkontribusi pada pengembangan teknologi berbasis kecerdasan buatan untuk meningkatkan kualitas produksi daun teh di Indonesia.

Kata Kunci: *Camellia sinensis*, CNN, VGG16, deteksi penyakit daun, klasifikasi gambar.

**Abstract** - *Camellia sinensis* or tea leaves have an important role in the Indonesian economy, but tea leaf production is often hampered by leaf diseases such as *Brown Blight* caused by *Colletotrichum camelliae*. This study aims to detect diseases in *Camellia sinensis* leaves using the *Convolutional Neural Network* (CNN) method with the VGG16 architecture. The dataset used includes various disease categories, including *Anthrachnose*, *Algal Leaf*, *Bird Eye Spot*, *Brown Blight*, *Gray Blight*, *Red Leaf Spot*, *White Spot*, and the *Healthy* category. The model was trained for 50 epochs with a final training accuracy of 97.03% and a loss of 0.2122, while evaluation on the testing dataset showed an accuracy of 68.59% and a loss of 0.8518. Individual prediction analysis of the 26th sample showed the success of the model in predicting *Algal Leaf* with a probability of 99.37%. The results of this study indicate that the VGG16 architecture is effective for disease detection in *Camellia sinensis* leaves, with suggestions to improve model generalization through data augmentation techniques, dataset addition, and training parameter optimization. This study contributes to the development of artificial intelligence-based technology to improve the quality of tea leaf production in Indonesia.

Keywords: *Camellia sinensis*, CNN, VGG16, leaf disease detection, image classification.

## PENDAHULUAN

Teh adalah salah satu minuman yang paling populer di dunia, dibuat dari daun dan pucuk tanaman *Camellia sinensis* (Kurnia Ramdan et al., 2022). Tumbuhan teh memiliki beberapa manfaat dan kegunaan, seperti antikanker, antioksidan, antimutagenik, antivirus, serta antibakteri (Fitri & Kusumawardhani, 2023). Di Indonesia, daun teh (*Camellia Sinesis*) adalah salah satu komoditas perkebunan yang memiliki peranan penting dalam perekonomian, serta memiliki berkontribusi signifikan terhadap devisa negara, bersaing dengan minyak dan gas (*Statistik-Teh-Indonesia-2022*, n.d.).

Pengendalian mutu *Camellia sinensis* umumnya dilakukan mulai dari analisis pucuk daun segar (PMS), pengawasan proses pengolahan, hingga evaluasi produk akhir melalui analisis grade (peko, jikeng, bubuk, tulang/batang) dan uji organoleptic (Lestari et al., 2023). Pengawasan kualitas pada masa panen *camellia sinensis*, tentu


sangat mempengaruhi hasil produksi, tercatat data statistik yang didapat dari BPS (badan pusat statistik) indonesia produksi teh di Indonesia pada tahun 2022 mengalami penurunan sebesar 9,56% dengan jumlah produksi 124,7 ribu ton dibandingkan dengan tahun 2021 (Statistik-Teh-Indonesia-2022, n.d.). Beragam usaha pengolahan dan penerapan teknologi secara rutin menghadapi batasan sehingga tidak dapat memenuhi proyeksi kebutuhan produksi. Salah satu faktor utama yang mengakibatkan penurunan produksi *Camellia sinensis* adalah penyakit pada daun, khususnya *Brown Blight* yang disebabkan oleh *Colletotrichum camelliae* (Diah et al., n.d.).

Studi terdahulu menunjukkan bahwa metode K-Nearest Neighbors (KNN) untuk klasifikasi penyakit daun anggur menghasilkan akurasi terbaik sebesar 71% pada K=1 (Safitri et al., 2024). Sebaliknya, penggunaan metode Convolutional Neural Network (CNN) untuk deteksi penyakit daun kentang pada epoch ke-10 dengan batch size 20 menghasilkan training accuracy sebesar 95% dan validation accuracy sebesar 94% (Rozaqi et al., 2021). Berdasarkan penelitian local lainnya, *Convolutional Neural Network* (CNN) dikenal mampu menghasilkan akurasi yang tinggi dalam mendeteksi daun karena arsitektur jaringannya yang dalam serta kemampuannya dalam mengekstraksi fitur secara otomatis dari citra yang kompleks (Alidrus et al., 2021).

*Deep learning* merupakan bagian krusial dari *machine learning* yang digunakan dalam prediksi, deteksi objek, dan diagnosis penyakit berbasis citra (Setyadi et al., 2024). *Convolutional Neural Network* (CNN) merupakan algoritma *deep learning* yang dirancang untuk mengolah data visual dua dimensi seperti gambar (Pujiati & Rochmawati, 2022). CNN telah digunakan secara luas dalam tugas pengenalan pola dan klasifikasi citra karena kemampuannya menangkap fitur kompleks. *Convolutional Neural Network* (CNN) adalah salah satu metode dalam jaringan saraf tiruan yang digunakan untuk mengenali dan mendeteksi objek pada data yang diamati. (Abdillah et al., 2022). *Convolutional Neural Network* (CNN) merupakan metode *machine learning* turunan dari *Multi Layer Perceptron* (MLP) yang dirancang untuk memproses data dua dimensi (Christiawan et al., 2023). *Confusion Matrix* dalam deep learning merupakan sebuah metode untuk mengukur akurat atau tidaknya sebuah model (Prakosa et al., 2023). Dalam CNN terdapat banyak sekali arsitektur populer yang sering digunakan pada berbagai kasus, namun VGG16 dipilih dalam penelitian ini, karena mampu mengenali dan memahami pola serta struktur gambar secara mendalam, sehingga efektif untuk klasifikasi objek. Arsitektur ini juga memiliki kemampuan hierarkis untuk memahami fitur dari tingkat rendah hingga tinggi, menjadikannya cocok untuk deteksi penyakit tanaman (Mulyana & Muthmainnah, 2024).

Penelitian ini berfokus pada penerapan *Convolutional Neural Network* (CNN) dengan arsitektur VGG16 untuk mendeteksi penyakit pada daun *Camellia sinensis*. VGG16 adalah model CNN yang dikembangkan dari AlexNet, menggunakan kernel 3x3 dan memiliki 16 lapisan, termasuk 13 *convolutional layers* dan 3 *fully connected layers*, dengan sekitar 138 juta parameter (Suryaman et al., 2021). Dengan penerapan VGG16, diharapkan dapat mereduksi kegagalan panen dan meningkatkan kualitas produksi akibat penyakit pada *Camellia sinensis*.

## METODOLOGI PENELITIAN





Gambar 1. Tahapan Penelitian

Klasifikasi penyakit pada daun *Camellia sinensis* menggunakan model *Convolutional Neural Network* (CNN) dengan arsitektur VGG16 melibatkan beberapa tahapan yang terstruktur yang diilustrasikan pada Gambar.1 sebagai berikut:

### 1. Pengumpulan Data

Dalam penelitian ini, data dikumpulkan menggunakan dataset publik yang tersedia di platform Kaggle dengan jumlah gambar 886. Dataset tersebut berisi informasi berupa gambar-gambar terkait berbagai jenis penyakit pada daun tanaman *Camellia sinensis*.





Gambar 2 Jenis Penyakit Daun *Camellia Sinesis*

Beberapa kategori penyakit yang terdapat dalam dataset ini meliputi *Anthrachnose*, *Algal Leaf*, *Bird Eye Spot*, *Brown Blight*, *Gray Blight*, *Red Leaf Spot*, *White Spot*, serta kategori *Healthy* untuk daun yang sehat. Dataset ini digunakan sebagai basis untuk melatih dan menguji model klasifikasi yang dikembangkan dalam penelitian.

## 2. *Pre-Processing Data*

*Pre-Processing* data adalah tahap penting dalam penelitian deteksi penyakit pada tanaman cabai menggunakan metode CNN. Langkah ini bertujuan untuk mempersiapkan data gambar agar sesuai dengan format dan persyaratan input CNN, sehingga dapat meningkatkan performa dan akurasi model dalam mendeteksi penyakit. Berikut ini adalah rincian tahapan *Pre-Processing* data:

### 1) Pembagian Data

Pada tahap ini, dataset dibagi menjadi dua\ bagian, yaitu data training dan data validasi dengan pembagian 80% data training dan 30% data testing. Data training digunakan untuk melatih algoritma agar dapat mengenali pola dan karakteristik data. Sementara itu, data validasi diambil 20% dari data *train*, digunakan untuk mengukur performa algoritma yang telah dilatih dengan mengujinya pada data baru yang belum pernah dilihat sebelumnya. Pembagian ini bertujuan untuk memastikan model dapat bekerja secara optimal dan memiliki kemampuan generalisasi yang baik terhadap data yang belum dikenal.


Tabel 1 Hasil Pembagian Dataset

### 2) Penyesuaian Ukuran dan Format Gambar

Pada tahap ini, ukuran gambar dalam dataset yang 244x244 piksel diubah menjadi 255x255 piksel agar seluruh gambar memiliki ukuran seragam. Warna gambar dipertahankan dalam format RGB. Selain itu, format gambar asli (misalnya JPEG atau PNG) juga diubah menjadi format yang kompatibel dengan metode CNN untuk memastikan kelancaran proses pelatihan model.

#### a. Model CNN Arsitektur VGG16

Penerapan Convolutional Neural Network (CNN) dengan arsitektur VGG16 untuk mendeteksi penyakit pada daun *Camellia sinensis*. VGG16 adalah salah satu model CNN yang dikembangkan dari AlexNet, dirancang dengan kernel berukuran 3x3. Arsitektur ini terdiri dari 16 lapisan, termasuk 13 lapisan konvolusi (convolutional layers) dan 3 lapisan terhubung penuh (fully connected layers), dengan total sekitar 138 juta parameter. Struktur ini memungkinkan VGG16 untuk mengekstraksi fitur secara mendalam dari data gambar dan memberikan performa yang baik dalam tugas klasifikasi visual.



Gambar 3 Arsitektur VGG16

#### b. *Training Model*

Proses *training model* dilakukan menggunakan fungsi kerugian *Categorical Crossentropy* untuk mengukur perbedaan antara prediksi dan label sebenarnya. Optimizer yang digunakan adalah AdamW, yang menggabungkan keunggulan algoritma Adam dengan regulasi berat (*weight decay*) untuk mengurangi *overfitting*. Model dilatih dengan berbagai jumlah epoch 50, untuk memastikan performa yang optimal.

### c. Evaluasi Model

Evaluasi model dilakukan untuk mengukur kinerja dan efektivitas model yang telah dilatih dalam mendeteksi penyakit pada daun *Camellia sinensis*. Salah satu langkah utama adalah menggunakan data validasi yang terpisah dari data training untuk menguji kemampuan model dalam mengenali pola dari data baru yang belum pernah dilihat sebelumnya. Penggunaan data validasi ini bertujuan untuk mengevaluasi performa model secara obyektif tanpa risiko bias dari data pelatihan.

Beberapa metrik yang umum digunakan dalam evaluasi meliputi:

#### 1. Akurasi

Akurasi adalah metrik paling umum yang menunjukkan persentase prediksi benar yang dibuat model di seluruh sampel data.

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN} \quad (1)$$

#### 2. Precision

*Precision* menunjukkan seberapa akurat prediksi positif model. Dengan kata lain, berapa persentase data positif yang benar-benar positif.

$$Precesion = \frac{TP}{TP+FP} \quad (2)$$

#### 3. Recall

Recall menunjukkan kecukupan prediksi positif model tersebut. Dengan kata lain, berapa persentase data positif yang berhasil diprediksi oleh model.

$$Recall = \frac{TP}{TP+FN} \quad (3)$$

#### 4. F1-Score

F1-score adalah rata-rata harmonis antara *precision* dan *recall*, yang dihitung untuk menyeimbangkan kedua ukuran tersebut. F1-score sering digunakan ketika kita ingin mempertimbangkan *precision* dan *recall* secara bersamaan.

$$F1 - Score = \frac{2 \times (recall \times precesion)}{recall + precesion} \quad (4)$$

Keterangan:

- True Positive (TP): ini adalah kasus ketika model memprediksi kela positif dengan benar.
- True Negative (TN): ini adalah kasus ketika model memprediksi kelas negatif dengan benar.
- False Positive (FP ): Ini adalah kasus ketika model salah memprediksi kelas positif (juga dikenal sebagai kesalahan Tipe I).
- Flase Negative (FN): Ini adalah kasus ketika model salah memprediksi kelas negatif (juga dikenal sebagai kesalahan tipe II).

Sebagai langkah akhir, model diuji pada data uji (testing data) yang benar-benar baru guna memastikan kemampuan generalisasinya terhadap data yang tidak pernah digunakan selama pelatihan.

## 3. Hasil dan Pembahasan

### 3.1 Hasil Pelatihan Model


Proses pelatihan dilakukan selama 50 epoch, akurasi model meningkat secara bertahap dari 14.91% pada epoch pertama hingga 97.03% pada epoch terakhir. Sebaliknya, nilai loss menurun dari 2.1146 pada epoch pertama menjadi 0.2122 pada epoch ke-50. Proses ini menunjukkan bahwa model semakin mampu mempelajari pola data dengan baik seiring waktu.

Tabel 2. Hasil Epoch 50


| Epoch | Accuracy | Loss   |
|-------|----------|--------|
| 1     | 14,91%   | 2,1146 |
| 10    | 73,95%   | 0.8918 |

|           |        |        |
|-----------|--------|--------|
| <b>20</b> | 87,39% | 0.5215 |
| <b>30</b> | 92,92% | 0.3702 |
| <b>50</b> | 97,03% | 0.2122 |

Hasil tersebut menunjukkan bahwa model mengalami peningkatan yang signifikan dalam hal akurasi dan pengurangan loss yang konsisten seiring dengan bertambahnya epoch. Ini menunjukkan bahwa model dapat mempelajari pola-pola dalam data dengan sangat baik, namun perlu dicatat bahwa akurasi yang tinggi pada data pelatihan tidak selalu menjamin performa yang sama pada data yang belum pernah dilihat.



Gambar 4 Grafik Accuracy Train



Gambar 5 Grafik Loss Train

### 3.2 Evaluasi Model

Pada gambar hasil evaluasi model menunjukkan:

| Normalized confusion matrix  |             |            |               |             |            |         |               |            |
|------------------------------|-------------|------------|---------------|-------------|------------|---------|---------------|------------|
| Label Benar \ Label Prediksi | Anthracnose | algal leaf | bird eye spot | brown light | gray light | healthy | red leaf spot | white spot |
| Anthracnose                  | 0.60        | 0.00       | 0.20          | 0.00        | 0.15       | 0.00    | 0.00          | 0.05       |
| algal leaf                   | 0.04        | 0.74       | 0.00          | 0.04        | 0.00       | 0.00    | 0.00          | 0.17       |
| bird eye spot                | 0.10        | 0.00       | 0.55          | 0.05        | 0.25       | 0.05    | 0.00          | 0.00       |
| brown light                  | 0.00        | 0.00       | 0.00          | 0.87        | 0.00       | 0.09    | 0.00          | 0.04       |
| gray light                   | 0.10        | 0.00       | 0.14          | 0.05        | 0.71       | 0.00    | 0.00          | 0.00       |
| healthy                      | 0.00        | 0.00       | 0.00          | 0.13        | 0.00       | 0.80    | 0.00          | 0.07       |
| red leaf spot                | 0.00        | 0.03       | 0.00          | 0.03        | 0.00       | 0.03    | 0.76          | 0.14       |
| white spot                   | 0.03        | 0.17       | 0.00          | 0.14        | 0.00       | 0.03    | 0.03          | 0.59       |

Gambar 6 Confusion Matrix

Nilai-nilai pada matriks ini menunjukkan proporsi prediksi yang benar dan salah untuk setiap kategori penyakit daun yang diklasifikasikan oleh model. Nilai diagonal (misalnya, 0.60 untuk "Anthracnose" dan

0.74 untuk "*algal leaf*") menunjukkan tingkat akurasi prediksi yang tinggi untuk kelas tersebut, yang berarti model berhasil mengklasifikasikan kelas dengan benar pada proporsi tersebut. Nilai-nilai di luar diagonal menunjukkan kesalahan klasifikasi, di mana model salah memprediksi kelas tertentu dan mengklasifikasikannya ke kelas lain.

Sebagai contoh, pada kategori "*algal leaf*", model memiliki akurasi sebesar 74% dalam mengklasifikasikan daun dengan ganggang, namun ada sedikit kesalahan prediksi di mana sebagian kecil *alga leaf* diklasifikasikan sebagai "*healthy*" (0.17) dan "*bird eye spot*" (0.04). Sebaliknya, kategori "*brown light*" menunjukkan akurasi yang sangat baik, dengan 87% prediksi yang benar.


### 3.3 Evaluasi pada Dataset Test

Model diuji menggunakan dataset pengujian untuk menilai performanya terhadap data yang tidak pernah dilihat sebelumnya. Akurasi pada dataset *test* 68.59%, akurasi ini menunjukkan kemampuan model untuk mengenali pola dengan baik pada data yang tidak dilatih sebelumnya, meskipun masih ada ruang untuk perbaikan. Loss pada Dataset *test* 0.85, nilai loss yang cukup rendah menunjukkan bahwa model mampu meminimalkan kesalahan dalam prediksinya pada dataset pengujian.

### 3.4 Prediksi Individual pada Dataset Test

Pada prediksi individual terhadap sampel ke-26 dari dataset pengujian, label yang benar adalah 1 (*algal leaf*), yang merepresentasikan daun dengan ganggang. Probabilitas prediksi model menunjukkan nilai tertinggi pada kelas-1 (99.37%), Hal ini menunjukkan model memberikan keyakinan yang sangat tinggi terhadap prediksi kelas ini.

Label yang diprediksi adalah 1 (*algal leaf*), yang sesuai dengan label sebenarnya, menunjukkan bahwa prediksi berhasil dilakukan dengan benar.



Gambar 7. Hasil Prediksi

Hasil ini mengindikasikan bahwa model mampu mengenali fitur visual dari kategori ini dengan baik dan memberikan keputusan yang akurat pada sampel tertentu dari dataset pengujian.

## 4. Kesimpulan

Berdasarkan hasil pelatihan, evaluasi, dan analisis terhadap model yang telah dibangun, diperoleh kesimpulan sebagai berikut:

- Model dilatih selama 50 *epoch*, menghasilkan akurasi pelatihan akhir sebesar 97.03% dengan nilai *loss* sebesar 0.2122. Pada data validasi, model mencapai akurasi sebesar 65.47%, menunjukkan model telah mempelajari pola pada data pelatihan meskipun masih ada ruang untuk perbaikan dalam hal generalisasi.
- Pada dataset pengujian, model menunjukkan akurasi sebesar 68.59% dengan nilai *loss* sebesar 0.8518. Hasil ini menandakan bahwa model memiliki performa yang cukup baik dalam mengenali kategori gambar pada data baru yang tidak digunakan selama pelatihan.
- Analisis prediksi individual dilakukan pada salah satu sampel dari dataset *test* (sampel ke-26). Model berhasil memprediksi label yang benar, yaitu 1 (*algal leaf*), dengan probabilitas tertinggi sebesar 99.37%. Hal ini menunjukkan bahwa model memiliki kemampuan yang baik dalam mengenali fitur visual secara spesifik.
- Model yang dikembangkan memiliki performa yang cukup baik untuk tugas klasifikasi gambar. Akurasi yang stabil pada data pengujian dan kemampuan prediksi individual yang akurat menunjukkan bahwa model ini dapat diandalkan untuk klasifikasi gambar serupa. Namun, terdapat beberapa peluang

perbaikan, seperti mengoptimalkan parameter pelatihan, menggunakan teknik augmentasi data, atau menambah jumlah data pelatihan untuk meningkatkan kemampuan generalisasi model.

#### 5. Daftar Pustaka

- Abdillah, M., Rasyad, S., Alfarizal, N., Teknik Elektro, J., Studi Sarjana Terapan Teknik Elektro, P., Mekatronika, K., Negeri Sriwijaya, P., & Srijaya Negara Bukit Besar, J. (2022). Implementasi Sistem Pendeteksi Penggunaan Masker Berbasis Raspberry Pi 4 Menggunakan Metode Convolution Neural Network (CNN) pada Proses Screening Protokol Kesehatan COVID-19. *Ijccs*, 16(1), 1–5. <https://jurnal.polsri.ac.id/index.php/teknika/article/view/3393>
- Alidrus, S. A., Aziz, M., & Putra, O. V. (2021). Deteksi Penyakit Pada Daun Tanaman Padi Menggunakan Metode Convolutional Neural Network. *Seminar Nasional Mahasiswa Ilmu Komputer Dan Aplikasinya (SENAMIKA)*, 14(3), 62–67. <https://doi.org/10.36982/jiig.v14i3.3478>
- Christiawan, G. Y., Putra, R. A., Sulaiman, A., Poerbaningtyas, E., & Putri Listio, S. W. (2023). Penerapan Metode Convolutional Neural Network (CNN) Dalam Mengklasifikasikan Penyakit Daun Tanaman Padi. *J-Intech*, 11(2), 294–306. <https://doi.org/10.32664/j-intech.v11i2.1006>
- Diah, K., Puspita, A., Nilogiri, A., Oktavianto, H., & Jember, M. (n.d.). *Deteksi Penyakit Daun Teh Menggunakan Metode Convolutional Neural Network (CNN)*.
- Fitri, N. K., & Kusumawardhani, A. R. (2023). Review artikel: Uji Efektivitas Ekstrak Daun Teh Hijau Sebagai Antibakteri. *Journal of Pharmaceutical and Sciences*, 6(3), 1100–1105. <https://doi.org/10.36490/journal-jps.com.v6i3.181>
- Kurnia Ramdan, S. R., Yusuf, A. L., & Setiawan, A. (2022). Isolasi Dan Identifikasi Kafein Dari Daun The Hijau, Tah Hitam Dan The Olong Menggunakan Spektrofotometri UV Vis. *Pharmacy Genius*, 01(01), 62–73.
- Lestari, P. W., Putri, H. S., Prawira-Atmaja, M. iqlab, & Pujianto, T. (2023). Pengendalian Kualitas pada Proses Pengolahan Teh Hijau Menggunakan Metode Lean Six Sigma. *Jurnal Sains Teh Dan Kina*, 2(2), 71–85. <https://doi.org/10.22302/pptk.jur.jstk.v2i2.181>
- Mulyana, S., & Muthmainnah, I. (2024). Analisis Perbandingan Tingkat Akurasi Algoritma Cnn Dan Svm Dalam Klasifikasi Pada Daun Gedi, Daun Pepaya Dan Daun Ubi. *JATI (Jurnal Mahasiswa Teknik Informatika)*, 8(4), 6157–6162. <https://doi.org/10.36040/jati.v8i4.10144>
- Prakosa, A. B., Hendry, & Tanone, R. (2023). Implementasi Model Deep Learning Convolutional Neural Network (CNN) Pada Citra Penyakit Daun Jagung Untuk Klasifikasi Penyakit Tanaman. *Jurnal Pendidikan Teknologi Informasi (JUKANTI)*, 6(1), 107–116.
- Pujiati, R., & Rochmawati, N. (2022). Identifikasi Citra Daun Tanaman Herbal Menggunakan Metode Convolutional Neural Network (CNN). *Journal of Informatics and Computer Science (JINACS)*, 3(03), 351–357. <https://doi.org/10.26740/jinacs.v3n03.p351-357>

Rozaqi, A. J., Sunyoto, A., & Arief, M. rudyanto. (2021). Deteksi Penyakit Pada Daun Kentang Menggunakan Pengolahan Citra dengan Metode Convolutional Neural Network. *Creative Information Technology Journal*, 8(1), 22. <https://doi.org/10.24076/citec.2021v8i1.263>

Safitri, E., Heppy, R., Sibarani, R., Kiswanto, D., Komputer, I., Medan, U. N., Baru, K., Percut, K., Tuan, S., Serdang, K. D., & Utara, S. (2024). *KLASIFIKASI PENYAKIT DAUN ANGGUR BERBASIS CITRA MENGGUNAKAN METODE K-NEAREST NEIGHBORS ( KNN )*. 8(6), 12633–12642.

Setyadi, R. A., Rahman, S., Manurung, D., Hasanah, M., & Indrawati, A. (2024). Implementasi Transfer Learning Untuk Klasifikasi Penyakit Pada Daun Cabai Menggunakan Cnn. *Djtechno: Jurnal Teknologi Informasi*, 5(2), 304–315. <https://doi.org/10.46576/djtechno.v5i2.4642>

*statistik-teh-indonesia-2022*. (n.d.).

Suryaman, S. A., Magdalena, R., & Sa'idah, S. (2021). Klasifikasi Cuaca Menggunakan Metode VGG-16, Principal Component Analysis Dan K-Nearest Neighbor. *Jurnal Ilmu Komputer Dan Informatika*, 1(1), 1–8. <https://doi.org/10.54082/jiki.1>